

UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO

FACULTAD DE CIENCIAS DE LA COMPUTACIÓN

CARRERA DE SOFTWARE

Reporte del estudio

SIGA — Sistema Inteligente de Gestión de Aulas

Calidad de los requisitos funcionales elicitados por analistas humanos
frente a los generados por un modelo grande de lenguaje

Proyecto Fin de Curso — Entrega Final (2B)

Ingeniería de Requerimientos (ISR-401) — 4.º nivel

Equipo FGMMN

Sánchez Cornejo, Gary Alberto	Analista líder
Muñoz Quiñónez, Yeranick Esther	Documentación y gestión de evidencias

Docente responsable: Ing. Gleiston Guerrero Ulloa

Repositorio del proyecto:

https://github.com/gleiston-guerrero/SIGA_FGMMN_ISR401_AVANCE_2B

Quevedo, Los Ríos, Ecuador — Período Académico Ordinario 2026–2027

Resumen

Este reporte documenta la especificación de requisitos del Sistema Inteligente de Gestión de Aulas (SIGA), una plataforma de Internet de las Cosas y aprendizaje automático para la Facultad de Ciencias de la Computación de la Universidad Técnica Estatal de Quevedo, y el componente empírico que la acompaña. El sistema cubre monitoreo ambiental de aulas, control remoto de equipamiento, generación de alertas, análisis predictivo de fallos, gestión de solicitudes de mantenimiento y reportes administrativos. La especificación se rige por ISO/IEC/IEEE 29148:2018 y sus requisitos no funcionales se cuantifican sobre el modelo de calidad de ISO/IEC 25010:2023. El componente empírico es un cuasi-experimento apareado que compara la calidad de los requisitos funcionales elicitados por analistas humanos frente a los generados por un modelo grande de lenguaje a partir del mismo corpus de entrevistas anonimizadas, evaluados a ciegas por tres jueces independientes en cinco dimensiones: completitud, ausencia de ambigüedad, verificabilidad, corrección respecto de la fuente y consistencia interna. El estudio se registró previamente y su análisis es íntegramente reproducible desde los datos crudos con una sola orden. Los resultados no alcanzan significación tras la corrección por comparaciones múltiples, con una potencia estadística que el propio reporte cuantifica y discute como limitación central del trabajo.

Palabras clave. Ingeniería de requisitos • Elicitación • Calidad de requisitos • Modelos grandes de lenguaje • Estudio empírico • Aulas inteligentes

Abstract

This report documents the requirements specification of SIGA, an Internet of Things and machine learning platform for classroom management built for the Faculty of Computer Science at Universidad Técnica Estatal de Quevedo, together with its accompanying empirical component. The system covers environmental monitoring of classrooms, remote equipment control, alert generation, predictive equipment failure analysis, maintenance request lifecycle management, and administrative reporting. The specification follows ISO/IEC/IEEE 29148:2018, and its non-functional requirements are quantified against the ISO/IEC 25010:2023 product quality model. The empirical component is a paired quasi-experiment comparing the quality of functional requirements elicited by human analysts against those generated by a large language model from the same anonymised interview corpus, blind-rated by three independent judges across five dimensions: completeness, absence of ambiguity, verifiability, correctness with respect to the source, and internal consistency. The study protocol was preregistered, and the analysis is fully reproducible from raw data with a single command. Results do not reach significance after correction for multiple comparisons, with a statistical power that this report quantifies and discusses as the central limitation of the work.

Keywords. Requirements engineering • Elicitation • Requirements quality • Large language models • Empirical study • Smart classrooms

Índice

Resumen	1
Abstract	1
1. Introducción	5
1.1. Problema y contexto	5
1.2. Brecha de conocimiento	5
1.3. Pregunta de investigación	5
2. Trabajo relacionado	6
3. Metodología	6
3.1. Diseño del estudio	6
3.2. Participantes	6
3.3. Instrumentos	7
3.4. Plan de análisis	7
4. Ejecución del estudio	8
4.1. Procedimiento	8
4.2. Codificación temática	8
4.3. Evaluación ciega	8
5. Resultados	9
5.1. Acuerdo entre evaluadores	9
5.2. Estadísticos descriptivos	10
5.3. Pruebas de supuestos	10
5.4. Contraste de hipótesis	11
5.5. Magnitud del efecto	11
5.6. Saturación temática	12
5.7. Potencia estadística	13
6. Discusión	13
6.1. Qué muestran los datos	13
6.2. La consistencia interna como señal a explorar	14
6.3. El acuerdo entre evaluadores acota la conclusión	14
6.4. Qué aporta el diseño de material fuente compartido	14

7. Amenazas a la validez	14
7.1. Validez de conclusión	14
7.2. Validez interna	15
7.3. Validez de constructo	15
7.4. Validez externa	15
7.5. Desviaciones respecto del protocolo registrado	15
8. Especificación final y trazabilidad	16
8.1. Síntesis de la especificación	16
8.2. Auditoría de calidad de la especificación	16
8.3. Trazabilidad extremo a extremo	17
8.4. Huérfanos y cadenas rotas	17
8.5. Línea base congelada	18
9. Requisitos de los componentes de inteligencia artificial	18
10. Retrospectiva	18
11. Conclusiones	19
11.1. Trabajo futuro	19
12. Disponibilidad de datos	19
13. Ética y protección de datos	20
Referencias	23
A. Instrumento de auditoría de calidad	24
B. Banco de preguntas del tribunal	24
C. Aporte individual	24
D. Retrospectiva del equipo	25
E. Declaración de uso de inteligencia artificial	27
F. Correspondencia entre afirmación y resultado	27

Índice de tablas

1.	Inter-rater agreement: pairwise Cohen kappa and overall Fleiss kappa, each with its 95 % bootstrap confidence interval (10,000 resamples of items)	9
2.	Descriptive statistics by quality dimension and requirement source	10
3.	Assumption checks: normality (Shapiro-Wilk) and homogeneity of variances (Levene)	10
4.	Paired hypothesis tests by dimension ($n = 3$ judges) with Holm-Bonferroni correction, and effect sizes with the requirement as the unit (25 human vs. 26 LLM; independent groups, so no pairs)	11
5.	Statistical power calculation for the paired t-test	13
6.	Métricas de calidad de la especificación.	24
7.	Retrospectiva por categoría, con responsable y acción.	25
8.	Observaciones del docente, resolución y evidencia.	26
8.	Observaciones del docente, resolución y evidencia.	27
9.	Trazado de las afirmaciones de la discusión.	28

Índice de figuras

1.	Acuerdo entre evaluadores por dimensión.	9
2.	Distribución de las puntuaciones por dimensión y origen.	10
3.	Tamaños del efecto con el requisito como unidad (25 frente a 26), con intervalo de confianza al 95 %.	12
4.	Códigos temáticos nuevos por entrevista, en orden cronológico.	12

1. Introducción

1.1. Problema y contexto

La Facultad de Ciencias de la Computación de la Universidad Técnica Estatal de Quevedo gestiona sus aulas sin ningún sistema de monitoreo. La detección de una falla depende de que una persona pase por el aula y la reporte, y el reporte viaja por canales informales sin registro. El trabajo de campo de este proyecto documentó ese circuito en **dieciséis** entrevistas con tres perfiles: docencia, coordinación académica y conserjería e infraestructura.

La codificación temática de esas entrevistas produjo **136 fragmentos** codificados en 12 categorías. Las cuatro con mayor densidad son control remoto de equipos, gestión de mantenimiento y tickets, monitoreo y visibilidad, y adopción y confianza. Esa distribución no es casual: describe un problema operativo con un componente humano de confianza que ninguna solución puramente técnica resuelve.

SIGA responde a ese problema con seis capacidades: monitoreo ambiental en tiempo real, control remoto de proyectores y climatización, alertas automáticas ante condiciones anómalas, análisis predictivo de fallos de equipamiento, gestión del ciclo de vida de solicitudes de mantenimiento, y reportes administrativos exportables. El dominio de las aulas inteligentes cuenta con antecedentes documentados en la literatura de campus inteligentes [1, 2, 3].

1.2. Brecha de conocimiento

La aparición de modelos grandes de lenguaje ha abierto una línea de trabajo sobre su uso en tareas de ingeniería de requisitos [4, 5, 6]. Existen estudios sobre generación de requisitos con estos modelos [7, 8, 9] y sobre su uso en contextos ágiles [10, 11].

La brecha que este trabajo aborda es de diseño comparativo. La mayor parte de los estudios revisados compara conjuntos de requisitos producidos a partir de material fuente distinto, de modo que la diferencia observada confunde el efecto del origen con el efecto del material. **Este estudio usa el mismo corpus de entrevistas para ambos brazos**, lo que aísla el origen como única variable que cambia.

1.3. Pregunta de investigación

La pregunta registrada en el protocolo, en su formulación literal, es:

¿En qué dimensiones de calidad los requisitos funcionales elicitados por un equipo humano difieren de los generados por un modelo de lenguaje grande a partir del mismo material fuente?

Las hipótesis asociadas, también registradas antes de recolectar, son: **H0**, no hay diferencia significativa en la puntuación media de calidad entre el conjunto generado por el modelo y el elicitado por el equipo humano en ninguna de las cinco dimensiones; **H1**, existe diferencia significativa en al menos una dimensión.

2. Trabajo relacionado

El estudio se apoya en tres cuerpos de literatura. El primero es normativo y metodológico: ISO/IEC/IEEE 29148:2018 fija la estructura y los atributos de una especificación [12], ISO/IEC 25010:2023 aporta el modelo de calidad sobre el que se cuantifican los requisitos no funcionales [13], y las obras de referencia del área [14, 15, 16] sostienen las decisiones de elicitación y especificación.

El segundo es el de modelos de lenguaje aplicados a requisitos. Los trabajos revisados se agrupan en tres líneas: generación de requisitos a partir de material fuente [7, 8, 9, 17], asistencia en tareas de análisis y clasificación [4, 6, 18], y uso en flujos ágiles y de gestión [10, 11, 19, 20]. La conclusión transversal de esa literatura es que los modelos producen requisitos sintácticamente correctos con rapidez, y que el punto débil declarado con más frecuencia es la trazabilidad a la fuente.

El tercero es metodológico-empírico y gobierna cómo se ejecutó este estudio: guías de experimentación en ingeniería de software [21, 22], de estudios de caso [23], de reporte [24], de encuestas [25, 26], de saturación temática [27, 28], de registro previo [29] y de acuerdo entre evaluadores [30, 31, 32].

Para los requisitos de explicabilidad del componente de inteligencia artificial se sigue el marco de Chazette y colaboradores [33, 34, 35], y para la publicación del paquete de datos, los principios FAIR [36] y las convenciones de citación de software [37, 38].

3. Metodología

3.1. Diseño del estudio

El estudio sigue un diseño cuasi-experimental apareado. La variable independiente es el origen del conjunto de requisitos funcionales, con dos niveles: elicitación por analistas humanos del equipo y generación por un modelo grande de lenguaje a partir del mismo material fuente. Las variables dependientes son las cinco dimensiones de calidad de la rúbrica de evaluación ciega.

El apareamiento se establece por juez: cada evaluador puntúa los dos conjuntos, de modo que su severidad individual afecta por igual a ambos brazos y queda controlada. Como controles adicionales se fijó el mismo material fuente para los dos conjuntos, se aleatorizó el orden de presentación con semilla 20260802, y se ocultó el origen de cada ítem.

Las decisiones de diseño se tomaron antes de recolectar y quedaron registradas en el protocolo, cuyo comprobante de registro previo se conserva en `06_Experimento/registro_previo/`. La Sección 7 declara una desviación relevante sobre el momento de ese registro.

3.2. Participantes

El corpus del proyecto son **dieciséis entrevistas válidas**. El levantamiento se cerró inicialmente en diez, por autorización expresa del docente responsable ante la restricción de calendario; una **ronda terminal** realizada el 3 de septiembre de 2026 añadió seis entrevistas a docentes, identificadas como EV-20 a EV-25.

El análisis cualitativo de este reporte se sostiene sobre las dieciséis entrevistas. Las seis de la ronda terminal se codificaron el 6 de septiembre de 2026 y entran ya en la tabla de códigos y en la curva de saturación. El componente empírico del cuasi-experimento es harina de otro costal: sus dos conjuntos de requisitos se generaron a partir de las diez primeras y no se rehicieron, de modo que *esa* comparación sigue apoyada en diez. Los participantes corresponden a tres perfiles de la organización cliente: docencia (DOC), coordinación académica (COORD) y conserjería e infraestructura (CONS).

Una entrevista adicional, identificada como EV-15, fue realizada pero se **excluyó íntegramente** del corpus porque el participante no firmó el consentimiento informado, ni para la entrevista ni para la sesión de validación asociada. Ningún fragmento suyo se conserva en el repositorio, en la codificación temática ni en el material fuente del componente empírico.

Los tres jueces del componente empírico son independientes: el protocolo exige que ninguno sea una de las personas entrevistadas, para preservar la ceguera del diseño.

3.3. Instrumentos

Se aplicaron cuatro instrumentos, todos en su versión final y todos depositados en el repositorio.

El **guion de entrevista** está en 02_Evidencias/Guiones_Entrevista/, con su historial de versiones. Su versión 2.0 incorpora el recorrido guiado por el prototipo y dos preguntas diseñadas para producir umbrales cuantitativos en lugar de opiniones.

El **cuestionario** se aplicó a 60 respondientes y su exportación directa, con marca temporal, está en 02_Evidencias/Cuestionario/.

La **rúbrica de evaluación ciega** define las cinco dimensiones sobre una escala de 1 a 5, y el **paquete ciego** presenta los 51 ítems con identificador ciego y orden aleatorizado. Ambos están en 06_Experimento/instrumentos/.

El **registro de la generación** del conjunto de requisitos del modelo de lenguaje —la instrucción que recibió, cada acción que ejecutó, el modelo, la interfaz y el material fuente— consta en 06_Experimento/prompts_llm/.

3.4. Plan de análisis

El plan se declaró dentro del protocolo registrado, antes de observar los datos, y se ejecutó sin desviaciones en su secuencia:

1. Consolidación de las hojas de puntuación de los tres jueces.
2. Acuerdo entre evaluadores: κ de Cohen ponderado por par y κ de Fleiss por dimensión [30, 31].
3. Pruebas de supuestos: Shapiro-Wilk para normalidad y Levene para homogeneidad de varianzas.
4. Prueba de hipótesis por dimensión: t apareada cuando Shapiro-Wilk no rechaza normalidad, Wilcoxon de rangos con signo en caso contrario, con corrección de Holm-Bonferroni sobre las cinco comparaciones.
5. Tamaño del efecto: d de Cohen o δ de Cliff, con intervalo de confianza al 95 % por remuestreo bootstrap de 10 000 réplicas y semilla fija. En la ejecución se calculó con el requisito como

unidad y no con el juez, porque sobre tres observaciones el intervalo no es estimable; es la desviación 7, explicada en la Sección 5.5.

4. Ejecución del estudio

4.1. Procedimiento

El trabajo de campo se ejecutó entre el 14 de mayo y el 30 de julio de 2026. Cada sesión siguió la misma secuencia: lectura del consentimiento informado en voz alta, firma, inicio de la grabación, entrevista conforme al guion, y cierre con la información sobre derechos de acceso, rectificación y supresión de datos.

Todas las sesiones se registraron en video y en audio con dispositivos independientes, salvo la del 28 de julio, que se registró **solo en audio** por petición expresa del participante. El inventario técnico recoge **36 grabaciones** de las sesiones y de la validación comunicativa, 19 de vídeo y 17 de audio: nueve vídeos y diez audios están en la zona pública y las diecisiete restantes en el contenedor cifrado de 02_Evidencias/00_Restringido/. Todas se verifican por sondeo de códec y duración contra 02_Evidencias/00_Restringido/fichas_tecnicas.csv.

4.2. Codificación temática

Las dieciséis transcripciones se codificaron íntegramente. El resultado son **136 fragmentos** con su código, su categoría, el requisito que derivan y la evidencia de la que proceden, repartidos en **50 códigos** y 12 categorías. La cobertura es del 100 % de las transcripciones: las dieciséis aportan al menos un fragmento codificado.

La codificación se repartió entre los tres integrantes por entrevista completa, y la columna **Analista_codificador** registra quién codificó cada fragmento. Cada cita se comprobó **literal** contra su transcripción y dentro de un turno del participante, no del entrevistador, antes de incorporarse.

La curva de códigos nuevos por entrevista (Figura 4) es la evidencia de saturación exigida, y su lectura se discute en la Sección 5.6.

4.3. Evaluación ciega

Tres jueces independientes evaluaron **51 ítems** presentados con identificador ciego y orden aleatorizado, sin información sobre su origen. El conjunto se compone de 25 requisitos elicitados por el equipo humano y 26 generados por el modelo de lenguaje.

Cada juez puntúo cada ítem en las cinco dimensiones sobre una escala de 1 a 5, lo que produce $51 \times 5 \times 3 = 765$ puntuaciones individuales. Los juicios se conservan **sin agregar** en 07_Datos/datos_crudos/, un archivo por juez, tal como exige la conservación de juicios individuales.

5. Resultados

Ninguna cifra de esta sección se escribió a mano. Todas las tablas y figuras se generan desde los datos crudos con la orden única `python 07_Datos/scripts/ejecutar.py`, y la correspondencia entre cada número, su salida y la etapa que la produce está en el apartado 6 de `07_Datos/README_datos.md`.

5.1. Acuerdo entre evaluadores

Tabla 1: Inter-rater agreement: pairwise Cohen kappa and overall Fleiss kappa, each with its 95 % bootstrap confidence interval (10,000 resamples of items)

Dimension	κ J1-J2	κ J1-J3	κ J2-J3	Fleiss κ
Compleitud	0.474 [0.311, 0.610]	0.646 [0.524, 0.751]	0.420 [0.231, 0.589]	0.338 [0.197, 0.467]
Ausencia_ambigüedad	0.654 [0.509, 0.770]	0.549 [0.396, 0.679]	0.494 [0.320, 0.635]	0.340 [0.205, 0.460]
Verificabilidad	0.646 [0.517, 0.755]	0.550 [0.404, 0.673]	0.419 [0.257, 0.557]	0.296 [0.171, 0.407]
Correccion_fuente	0.444 [0.259, 0.615]	0.396 [0.228, 0.556]	0.316 [0.084, 0.525]	0.294 [0.143, 0.438]
Consistencia_interna	0.577 [0.400, 0.736]	0.467 [0.271, 0.628]	0.294 [0.085, 0.491]	0.333 [0.171, 0.480]

La Tabla 1 recoge los coeficientes de acuerdo por dimensión. El κ de Fleiss se sitúa entre 0,294, con intervalo de confianza al 95 % de [0,143; 0,438], y 0,340, con [0,205; 0,460], según la dimensión; la tabla da el intervalo de cada coeficiente, calculado por bootstrap de ítems. En la escala de Landis y Koch [32] ese rango corresponde a acuerdo **justo**, el segundo de seis niveles. Los κ de Cohen por pares son superiores, entre 0,294 y 0,654, lo que indica que la discrepancia no se concentra en un juez aislado sino que se reparte entre los tres.

La Figura 1 muestra el reparto del acuerdo entre las cinco dimensiones. Se reporta como acuerdo justo, no como acuerdo bueno. La consecuencia sobre la interpretación se trata en la Sección 7.




Figura 1: Acuerdo entre evaluadores por dimensión.

Tabla 2: Descriptive statistics by quality dimension and requirement source

Dimension	Source	Median	Mean	SD	Min	Max	IQR
Compleitud	Humano	4.000	3.907	1.016	2.000	5.000	2.000
Compleitud	LLM	4.000	4.115	0.868	2.000	5.000	1.000
Ausencia_ambigüedad	Humano	4.000	3.613	1.051	1.000	5.000	1.000
Ausencia_ambigüedad	LLM	4.000	3.859	0.977	1.000	5.000	2.000
Verificabilidad	Humano	4.000	3.653	1.033	1.000	5.000	1.500
Verificabilidad	LLM	4.000	3.872	1.121	1.000	5.000	2.000
Correccion_fuente	Humano	4.000	4.293	0.731	3.000	5.000	1.000
Correccion_fuente	LLM	5.000	4.487	0.597	3.000	5.000	1.000
Consistencia_interna	Humano	4.000	4.147	0.817	2.000	5.000	1.000
Consistencia_interna	LLM	4.000	4.385	0.669	3.000	5.000	1.000

5.2. Estadísticos descriptivos

La Tabla 2 reúne medias y desviaciones por dimensión y origen. El conjunto generado por el modelo obtiene una media superior en **las cinco dimensiones**. La diferencia oscila entre 0,20 y 0,25 puntos sobre la escala de 1 a 5. Las dos dimensiones con puntuación más alta en ambos brazos son corrección respecto de la fuente y consistencia interna; la más baja en ambos es ausencia de ambigüedad. La Figura 2 deja ver que las distribuciones de ambos brazos se solapan ampliamente en todas las dimensiones.




Figura 2: Distribución de las puntuaciones por dimensión y origen.

5.3. Pruebas de supuestos

Tabla 3: Assumption checks: normality (Shapiro-Wilk) and homogeneity of variances (Levene)

Dimension	<i>n</i>	SW <i>p</i> (Human)	SW <i>p</i> (LLM)	Normal (H)	Normal (L)	Levene <i>W</i>	Levene <i>p</i>	Equal var.
Compleitud	3	0.780	0.537	Sí	Sí	0.122	0.745	Sí
Ausencia_ambigüedad	3	0.253	0.843	Sí	Sí	0.002	0.969	Sí
Verificabilidad	3	0.780	0.637	Sí	Sí	0.458	0.536	Sí
Correccion_fuente	3	0.298	0.000	Sí	No	0.115	0.751	Sí
Consistencia_interna	3	0.843	0.537	Sí	Sí	0.002	0.964	Sí

La Tabla 3 resume ambos contrastes. Shapiro-Wilk no rechaza la normalidad en nueve de las diez combinaciones de dimensión y origen. La excepción es corrección respecto de la fuente en el conjunto del modelo, y por eso esa única dimensión se contrastó con Wilcoxon de rangos con

signo y su tamaño del efecto se expresó como δ de Cliff. Levene no rechaza la homogeneidad de varianzas en ninguna dimensión.

La selección de prueba por dimensión se hizo conforme a la regla declarada en el protocolo, no tras observar los resultados.

5.4. Contraste de hipótesis

Tabla 4: Paired hypothesis tests by dimension ($n = 3$ judges) with Holm-Bonferroni correction, and effect sizes with the requirement as the unit (25 human vs. 26 LLM; independent groups, so no pairs)

Dimension	Test	Stat.	Value	p	p_{holm}	Effect size (per requirement)	Value	95% CI	Pairs	Interpretable
Compleitud	t apareada	t	-1.804	0.213	0.426	delta de Cliff	-0.117	[-0.434, 0.200]	–	yes
Ausencia_ambigüedad	t apareada	t	-4.071	0.055	0.222	g de Hedges	-0.257	[-0.824, 0.298]	–	yes
Verificabilidad	t apareada	t	-2.534	0.127	0.380	delta de Cliff	-0.143	[-0.459, 0.177]	–	yes
Correccion_fuente	Wilcoxon de rangos con signo	W	1.000	0.500	0.500	delta de Cliff	-0.178	[-0.477, 0.128]	–	yes
Consistencia_interna	t apareada	t	-9.123	0.012	0.059	delta de Cliff	-0.185	[-0.478, 0.126]	–	yes

La Tabla 4 recoge el estadístico, el valor p sin ajustar y el ajustado de cada dimensión. Antes de corregir por comparaciones múltiples, una dimensión queda por debajo de $\alpha = 0,05$: consistencia interna, con $p = 0,0118$. Tras aplicar Holm-Bonferroni sobre las cinco comparaciones, ese valor asciende a $p = 0,059$ y **ninguna dimensión alcanza significación**. La segunda más próxima, ausencia de ambigüedad, pasa de $p = 0,0554$ a $p = 0,2216$.

No se rechaza H_0 en ninguna de las cinco dimensiones.

5.5. Magnitud del efecto

El contraste anterior se hace sobre las medias de los tres jueces, como fija el protocolo. **El tamaño del efecto no se calcula sobre esas tres observaciones**: con $n = 3$ el remuestreo bootstrap solo puede formar unas pocas muestras distintas, varias con desviación nula, y el intervalo que produce no estima nada. Por eso se calcula con el **requisito** como unidad: se promedian los tres jueces en cada requisito y se comparan los 25 del equipo con los 26 del modelo, que son muestras independientes. Se usa g de Hedges cuando Shapiro-Wilk no rechaza la normalidad en ninguno de los dos grupos y δ de Cliff en caso contrario, con intervalo de confianza al 95 % por bootstrap estratificado de 10 000 réplicas y semilla 20260802. El cambio está declarado como desviación 7 en `07_Datos/desviaciones.md`.

Los efectos son **pequeños**: δ de Cliff entre $-0,117$ y $-0,185$ en cuatro dimensiones y $g = -0,257$ en ausencia de ambigüedad, con signo negativo porque el conjunto humano puntúa por debajo del generado. **Todos los intervalos incluyen el cero**; el más amplio va de $-0,824$ a $0,298$. La Tabla 4 recoge cada valor con su intervalo junto al contraste de su dimensión. Sus dos últimas columnas atienden la evaluación del 2026-09-14: *Pairs* indica los pares efectivos —ninguno, porque 25 y 26 requisitos son grupos independientes— e *Interpretable* lo calcula el propio script, no se escribe a mano: vale *sí* cuando el efecto descansa en al menos diez unidades y su intervalo es finito y no cubre todo el recorrido del estimador. Las cinco dimensiones cumplen; la d apareada sobre tres jueces que se retiró no habría cumplido en ninguna. Ambas columnas constan en `efectos.csv` y en su diccionario de datos.

Un efecto pequeño con un intervalo que cruza el cero no sostiene una afirmación sobre la dirección de la diferencia, y así se reporta.




Figura 3: Tamaños del efecto con el requisito como unidad (25 frente a 26), con intervalo de confianza al 95 %.

5.6. Saturación temática




Figura 4: Códigos temáticos nuevos por entrevista, en orden cronológico.

La curva acumula **50 códigos** a lo largo de las **dieciséis** entrevistas. El criterio de saturación declarado — promedio de códigos nuevos de las tres últimas entrevistas por debajo del 5 % del total acumulado — se cumple a partir de EV-23, la decimocuarta: 2,333 frente a un umbral de

2,35, y con las dieciséis el promedio baja a **1,333** frente a un umbral de **2,50**.

La saturación temática se alcanzó, y conviene decir con qué reservas, porque un resultado que cambia justo cuando conviene hay que sostenerlo mejor que uno que no cambia nada.

Primera comprobación: no depende del orden. El criterio mira las tres últimas entrevistas, y las seis que cerraron el corpus se hicieron *el mismo día*, de modo que su posición en la serie la fija el número de evidencia y no la hora. Si la saturación dependiera de cuál quedó última sería un accidente de la numeración. Se probaron las **720 ordenaciones posibles** de ese bloque y satura en las 720; el peor caso da 2,333 frente al umbral de 2,50. El script que lo reproduce es `02_Evidencias/Codificacion_Tematica/robustez_saturacion.py`.

Tres reservas que se declaran. La primera: las instrucciones de codificación pedían expresamente reutilizar códigos antes que inventarlos, lo que es correcto — multiplicar sinónimos falsea la curva en la otra dirección — pero empuja hacia el resultado obtenido. Las tasas de reuso de los tres codificadores caen en cinco puntos (59 %, 63 % y 64 %), de modo que el sesgo, si lo hay, está repartido y no concentrado en una persona. La segunda: las seis entrevistas que cierran la serie son todas del perfil docente, y saturar dentro de un perfil no es saturar el dominio. La tercera: siete de los catorce códigos nuevos aparecen en una sola entrevista; seis de esos siete refuerzan requisitos que ya tenían otra fuente, pero **RNF-15** descansa entero sobre **EV-20**.

Las tres constan en `02_Evidencias/Codificacion_Tematica/00_LEEME_SATURACION.md`.

5.7. Potencia estadística

Tabla 5: Statistical power calculation for the paired t-test

Target d	α	Target power	n needed	n needed (int.)	n actual	Power achieved
0.5000	0.0500	0.8000	33.3700	34	3	0.0841

El cálculo completo está en la Tabla 5. Para detectar un efecto de tamaño $d = 0,50$ con $\alpha = 0,05$ y potencia 0,80 se requieren 34 unidades de análisis. El estudio dispone de tres. La potencia efectivamente alcanzada es del **8,4 %**.

Esa cifra es la clave para leer todo lo anterior: con esa potencia, la ausencia de significación era el resultado esperable con independencia de que exista o no una diferencia real.

6. Discusión

Cada afirmación de esta sección remite a un resultado concreto. La correspondencia completa está en el Anexo F.

6.1. Qué muestran los datos

El conjunto generado por el modelo obtuvo una media superior en las cinco dimensiones evaluadas, con diferencias de entre 0,20 y 0,25 puntos. **Esa superioridad no es estadísticamente sostenible**: ninguna dimensión sobrevive a la corrección por comparaciones múltiples y todos los intervalos de confianza del tamaño del efecto incluyen el cero.

La lectura honesta de este estudio es que **no permite distinguir la calidad de ambos orígenes**, y que la causa principal de esa incapacidad es su propia potencia del 8,4 %, no una equivalencia demostrada entre los brazos. Ausencia de evidencia no es evidencia de ausencia.

6.2. La consistencia interna como señal a explorar

La única dimensión que se aproximó a la significación fue consistencia interna, que pasó de $p = 0,0118$ a $p = 0,059$ tras la corrección. Es también la dimensión con el δ de Cliff mayor en valor absoluto, $-0,185$, aunque su intervalo incluye el cero.

Una explicación plausible, coherente con la literatura revisada [7, 8], es que un modelo que genera los 26 requisitos en una sola pasada mantiene un vocabulario y una estructura de plantilla más uniformes que un equipo que redacta a lo largo de semanas. Esa uniformidad se puntuaría como consistencia.

Se enuncia como hipótesis a contrastar, no como hallazgo: con esta potencia el estudio no la sostiene.

6.3. El acuerdo entre evaluadores acota la conclusión

El κ de Fleiss entre 0,294 y 0,340 indica acuerdo justo. Eso significa que una parte apreciable de la varianza observada procede de cómo cada juez interpreta la rúbrica, y no de la calidad de los requisitos.

La implicación práctica es directa: antes de ampliar la muestra conviene refinar la rúbrica y calibrar a los jueces con ítems de entrenamiento. Ampliar la muestra sobre un instrumento con acuerdo justo multiplica el ruido junto con la señal.

6.4. Qué aporta el diseño de material fuente compartido

La contribución metodológica de este trabajo no está en su resultado, que es nulo, sino en su diseño: ambos brazos parten del **mismo corpus** de entrevistas, de modo que la comparación no confunde el efecto del origen con el del material disponible. Ese control se mantuvo, y el pipeline que lo implementa queda publicado y es ejecutable con una sola orden.

Un equipo que quiera repetir el estudio con una muestra suficiente puede reutilizar el protocolo, los instrumentos, el paquete ciego y los scripts sin reconstruir nada.

7. Amenazas a la validez

Se declaran con su mitigación aplicada y su limitación remanente, siguiendo la clasificación habitual [21, 23].

7.1. Validez de conclusión

Amenaza. La potencia estadística es del 8,4 %, frente a las 34 unidades que requeriría el diseño. La unidad de análisis empleada es el juez, con $n = 3$ y dos grados de libertad.

Mitigación aplicada. Se calculó y se publicó la potencia en lugar de omitirla; se aplicó corrección de Holm-Bonferroni pese a saber que ninguna dimensión la superaría; y se reportan intervalos de confianza que exhiben la falta de precisión en lugar de ocultarla tras el valor puntual.

Limitación remanente. El estudio no puede sostener ninguna afirmación direccional. Un análisis con el ítem como unidad, sobre los 51 ítems en lugar de los 3 jueces, elevaría sustancialmente la potencia sin recolectar un solo dato nuevo; queda como el trabajo futuro de mayor rendimiento.

7.2. Validez interna

Amenaza. El equipo que elicitó el conjunto humano es el mismo que diseñó el estudio, lo que abre la puerta a un sesgo a favor de su propio brazo.

Mitigación aplicada. La evaluación la realizaron tres jueces independientes que no participaron en la elicitación, sobre un paquete ciego con orden aleatorizado y semilla fija, sin indicación de origen.

Limitación remanente. El material fuente y la rúbrica los preparó el equipo. La ceguera cubre la evaluación, no la construcción del instrumento.

7.3. Validez de constructo

Amenaza. La rúbrica de cinco dimensiones es un aproximante de un constructo — la calidad de un requisito — que la propia disciplina no define de forma unívoca. El κ justo indica que las dimensiones no se interpretan igual entre jueces.

Mitigación aplicada. Las cinco dimensiones se tomaron de atributos reconocidos en ISO/IEC/IEEE 29148:2018 [12] y no se redefinieron tras ver los datos. El acuerdo se midió y se reportó con una escala publicada.

Limitación remanente. Sin calibración previa de los jueces, parte de la varianza es de instrumento y no de objeto.

7.4. Validez externa

Amenaza. Un único dominio, una única organización, un único modelo de lenguaje y una única sesión de generación.

Mitigación aplicada. El contexto se describe con detalle suficiente para juzgar la transferibilidad, y el paquete de replicación permite repetir el procedimiento en otro dominio.

Limitación remanente. Los resultados no se generalizan más allá de este caso. La comparación con otros modelos queda fuera del alcance.

7.5. Desviaciones respecto del protocolo registrado

Se declaran aquí, y en la bitácora de `06_Experimento/registro_previo/`, las desviaciones ocurridas.

Momento del registro previo. El protocolo se registró en el Open Science Framework el 2 de agosto de 2026. El trabajo de campo había concluido el 30 de julio, y los datos de la evaluación ciega ya estaban consolidados en el repositorio ese mismo 2 de agosto, con anterioridad al registro dentro de la jornada. En consecuencia, **el registro no es anterior al inicio de la recolección**, como exige la práctica de pre-registro [29]. Esta desviación no admite corrección retroactiva: se declara de forma expresa y el lector debe tratar el análisis como confirmatorio solo en la medida en que el plan estaba escrito antes de observar los resultados, y como exploratorio en todo lo demás.

Cierre de campo en diez entrevistas, y su reapertura. El cierre lo autorizó el docente responsable ante la restricción de calendario. La ronda terminal del 3 de septiembre de 2026 lo superó al elevar el corpus a dieciséis, y su codificación, hecha el 6 de septiembre, incorporó esas seis a la tabla de códigos y a la curva de saturación. La desviación respecto del protocolo se mantiene — el cierre se decidió cuando se decidió — pero ya no arrastra un corpus analizado más estrecho que el recogido. El efecto sobre la saturación se cuantifica en la Sección 5.6.

Exclusión de EV-15. Retiro del consentimiento por parte del participante. El material se eliminó íntegramente. Es una desviación obligada por la protección de datos, no una decisión metodológica.

Saturación alcanzada después del cierre autorizado. El protocolo prevía continuar hasta saturación, y el cierre en $N=10$ interrumpió esa condición: con diez entrevistas la curva no saturaba. La ronda terminal del 3 de septiembre añadió seis entrevistas más, codificadas el 6 de septiembre, y con las dieciséis el criterio se cumple. La desviación respecto del protocolo no desaparece — el cierre se decidió antes de saber esto — pero su consecuencia sí.

8. Especificación final y trazabilidad

8.1. Síntesis de la especificación

La versión 2.0 del ERS/SRS especifica **25 requisitos funcionales** con sus ocho atributos, **16 requisitos no funcionales** cuantificados sobre las características de ISO/IEC 25010:2023, 16 casos de uso textuales, 38 historias de usuario y 18 restricciones de diseño. El documento completo se entrega compilado en 01_ERS/.

8.2. Auditoría de calidad de la especificación

Las seis métricas se calcularon con sus conteos base publicados antes de medir. El detalle, con la aritmética visible, está en 01_ERS/Auditoria_Calidad/ y se resume en el Anexo A.

Tres métricas cumplen su valor de referencia y tres no. Los tres defectos concretos que la medición identificó son: una ficha de requisito con un atributo incompleto, un solapamiento funcional entre RF-13 y RF-16 — ambos apagan equipos de aulas desocupadas fuera de horario con el mismo umbral — y el criterio de verificación de RF-14, que exige recomendaciones «coherentes» sin definir métrica que permita a dos evaluadores independientes coincidir.

Un hallazgo merece mención aparte. La métrica automática de modificabilidad arrojaba 0,08 requisitos afectados por cambio, muy por debajo del umbral de 3,0. El análisis manual sobre

cinco requisitos representativos arrojaba **5,00**. La diferencia no era un error de cálculo: era el defecto. Las dependencias existían en el sistema pero no estaban declaradas en la especificación, de modo que el documento aparentaba un acoplamiento bajo que no tenía.

Corregido eso, las 25 fichas declaran hoy de qué requisitos dependen y a cuáles alimentan, con un grafo de 50 dependencias cuyo sentido inverso se deriva, de modo que ninguna puede figurar en una ficha y faltar en la otra. La medida automática y la manual coinciden ya en **4,00** sobre las 25 fichas. El valor *empeora* respecto del 0,08 declarado, y esa es la lectura correcta: el acoplamiento dejó de estar oculto. Sigue sin cumplir el umbral de 3,0, y bajarlo exige desacoplar los dos puntos de convergencia — la bitácora RF-23 y el panel RF-07 — lo que constituye un cambio de diseño y no una corrección de redacción.

8.3. Trazabilidad extremo a extremo

La matriz de trazabilidad contiene **75 filas**, por encima de las **60** que exige el criterio, y sin una sola celda vacía. De ellas, **59 cierran la cadena de extremo a extremo**; las 16 restantes se declaran una a una con su causa en `04_Trazabilidad/huerfanos_y_cadenas_rotas.md`: nueve son huérfanas porque el requisito nace de análisis normativo y no de campo, una está parcial a falta de una clase que la realice, y seis son restricciones de diseño con algún eslabón que no aplica, porque no se verifican por caso de prueba sino por revisión. La cifra se recalcula con `python 04_Trazabilidad/verificar_matriz.py`. Las ocho filas más recientes corresponden a los requisitos no funcionales del componente inteligente (RNF-IA-01 a RNF-IA-08), cada uno con su métrica, unidad, umbral, método de verificación, responsable y frecuencia de medición, según exige la sección 8 de la guía de desarrollo; seis de ellas cierran la cadena. Cada fila enlaza la evidencia de campo de la que procede el requisito con el requisito mismo, los casos de uso que lo realizan, la historia de usuario asociada, su criterio de aceptación, el componente de diseño que lo implementa y el prototipo de interfaz que lo soporta.

El caso de prueba que verifica cada requisito dejó de ser un identificador sin respaldo: `04_Trazabilidad/casos_prueba.csv` define los **49** que la matriz cita, con objetivo, precondition, procedimiento, resultado esperado y criterio de aceptación. El catálogo se genera por script y la generación falla si la correspondencia con la matriz se rompe en cualquiera de los dos sentidos. Dieciocho son ejecutables sobre el prototipo actual; los demás exigen un sistema desplegado, y ninguno se presenta como ejecutado.

El **96,0 %** de los requisitos funcionales tiene su fuente de campo identificada: 24 de los 25 enlazan a una evidencia **EV-*nn*** concreta. El restante, RF-25, procede del análisis normativo de la LOPDP y no de una entrevista, y se declara así en lugar de asignarle una fuente que no tiene.

Las cuatro columnas que la guía añade a la cadena —clase, proceso, caso de prueba y estado de la traza— están en la matriz, que pasó de 13 a 18 columnas, y ninguna celda queda en blanco: cada una declara si el eslabón existe o por qué no aplica.

8.4. Huérfanos y cadenas rotas

Los **25 requisitos funcionales** tienen la cadena adelante completa hasta criterio de aceptación (100,0 %). Los cinco de prioridad Should que no la tenían —RF-06, RF-09, RF-14, RF-17 y RF-18— la cerraron el 2026-09-12 con las historias HU-22 a HU-26 y sus criterios. Lo que no

cierra de extremo a extremo son las 16 filas descritas arriba, cada una con su causa y su acción en `04_Trazabilidad/huerfanos_y_cadenas_rotas.md`. Las cifras de esta sección se recalculan desde `04_Trazabilidad/matriz_trazabilidad.csv`.

8.5. Línea base congelada

La versión entregada corresponde a la etiqueta anotada `2B-final-v5.11`, la única vigente, publicada en el remoto y alcanzable desde la rama por defecto. Las anteriores, de `2B-final` a `2B-final-v5.10`, se conservan solo como referencia histórica, tal como declaran `README.md` y `CHANGELOG.md`. El manifiesto `checksums.sha256` se genera con `10_Autoria/generar_manifiesto.py` sobre todos los archivos versionados, salvo el propio manifiesto, y comprueba sin error sobre un clon limpio.

9. Requisitos de los componentes de inteligencia artificial

SIGA contiene **un único componente basado en aprendizaje automático**: RF-09, el análisis predictivo de fallos de equipamiento. Su ficha completa, con cuatro requisitos funcionales, cuatro de rendimiento, tres de equidad y uno de explicabilidad — todos con umbral, unidad y método de comprobación —, la especificación de sus datos de entrenamiento y su plan de monitoreo, está en `01_ERS/Componentes_IA/`.

RF-03, la detección de ocupación, **no es un componente de inteligencia artificial** con la especificación vigente: es un umbral determinista sobre la señal de un sensor de presencia, sin parámetros aprendidos. La clasificación deja registrado qué tres cambios de diseño obligarían a revisar esa decisión.

El requisito de explicabilidad EX-IA-01 concreta el marco de Chazette y colaboradores [33, 35]: la explicación de cada predicción se entrega al personal no técnico que decide la intervención, en lenguaje llano, en 60 palabras como máximo y en menos de dos segundos, y se valida con una prueba de comprensión en la que cuatro de cada cinco participantes deben poder explicarla con sus propias palabras.

El sistema se clasifica como de **riesgo mínimo** conforme al Reglamento (UE) 2024/1689, tras descartar una a una las cuatro hipótesis educativas de su Anexo III. El tratamiento de datos personales se rige por la Ley Orgánica de Protección de Datos Personales del Ecuador [39].

10. Retrospectiva

El detalle por categoría, con responsable y acción, está en el Anexo D, junto con las observaciones que el docente hizo durante el proyecto y cómo se resolvió cada una (Tabla 8). La retrospectiva del cierre, del 12 al 16/09/2026, con los reclamos que presentó el equipo y su resolución, quién hizo qué y lo aprendido, está en `10_Autoria/retrospectiva_equipo.md`. Tres aprendizajes resumen el proyecto.

El registro previo no admite improvisación. La desviación más costosa de este trabajo no fue metodológica sino de calendario: registrar el protocolo después de recolectar convierte un análisis confirmatorio en exploratorio, y no hay forma de repararlo después.

Una métrica que se ve bien merece más sospecha que una que se ve mal. La modificabilidad pasaba con enorme holgura porque el documento no declaraba sus dependencias. El defecto estaba en el indicador, no en el sistema.

La reproducibilidad hay que construirla antes de necesitarla. El pipeline que regenera cada tabla y cada figura desde los datos crudos permitió rehacer el análisis completo varias veces sin miedo. Ese trabajo se hizo tarde y habría rendido más temprano.

11. Conclusiones

Cada conclusión remite a un dato de este reporte.

Primera. El estudio **no encontró diferencia significativa** en ninguna de las cinco dimensiones de calidad entre los requisitos elicitados por el equipo humano y los generados por el modelo de lenguaje. Tras la corrección de Holm-Bonferroni, el menor valor ajustado es $p = 0,059$.

Segunda. Ese resultado **no debe leerse como equivalencia entre ambos orígenes**. Con una potencia del 8,4 % frente a las 34 unidades requeridas, el estudio carecía de capacidad para detectar el efecto que buscaba.

Tercera. La calidad de la medición está acotada por el acuerdo entre evaluadores, justo en la escala de Landis y Koch, con κ de Fleiss entre 0,294 y 0,340. Refinar la rúbrica y calibrar a los jueces es condición previa a ampliar la muestra.

Cuarta. La saturación temática **se alcanzó** al completar la codificación de las dieciséis entrevistas: el promedio de códigos nuevos de las tres últimas baja a 1,333 sobre 50 acumulados, por debajo del umbral de 2,50, y el resultado resiste las 720 ordenaciones posibles del bloque de entrevistas del mismo día. Se alcanza, eso sí, con un tramo final de un solo perfil, y esa limitación se declara.

Quinta. La especificación resultante cumple tres de las seis métricas de calidad auditadas, y las tres que no cumplen tienen su defecto identificado y su acción de mejora definida. El prototipo cubre 17 de los 20 requisitos obligatorios, un 85 %.

Sexta. La contribución que este trabajo deja disponible no es su resultado, sino su **diseño de material fuente compartido** y el paquete de replicación ejecutable que lo implementa.

11.1. Trabajo futuro

Por orden de rendimiento esperado: llevar la unidad de análisis al ítem, sobre los 51 disponibles, lo que eleva la potencia sin recolectar datos nuevos; calibrar a los jueces con ítems de entrenamiento antes de una nueva ronda; ampliar el panel de evaluadores; declarar las dependencias entre requisitos en la especificación y volver a medir modificabilidad; y repetir el estudio con más de un modelo de lenguaje.

12. Disponibilidad de datos

Los datos, los scripts y las salidas que sostienen cada cifra de este reporte están en el repositorio del proyecto, cuya dirección figura en la carátula. El paquete de replicación reside en

07_Datos/, con los datos crudos en formato abierto sin edición manual posterior, los datos procesados generados exclusivamente por script, el diccionario de datos con el significado, tipo y rango de cada variable, y la correspondencia explícita entre cada tabla y cada figura y el script que la produce.

El análisis completo se reproduce con una sola orden desde la raíz del repositorio:

```
cd 06_Experimento && make all
```

El manifiesto `checksums.sha256` cubre 248 archivos y comprueba sin error sobre un clon limpio. El código se publica bajo Apache-2.0 y los datos y documentos bajo CC BY 4.0, conforme a las prácticas FAIR [36] y de citación de software [37, 38].

13. Ética y protección de datos

Cada participante firmó un consentimiento informado antes de su sesión. Las copias publicadas están enmascaradas: la cédula y la firma no son legibles. Los originales se conservan fuera del repositorio, bajo custodia del docente responsable.

Los nombres propios se sustituyen por códigos de participante en todo el material publicado, incluidos los nombres de archivo. La correspondencia entre código y persona existe únicamente en el registro de custodia que se entrega al docente. El procedimiento completo de disociación está en `07_Publicacion/dataset_zenodo/anonimizacion.md`.

El caso de EV-15 ilustra que el derecho de retiro se ejerció y se respetó: el participante no firmó el consentimiento y su material fue eliminado íntegramente, sin conservar ningún fragmento. La base legal del tratamiento, la política de conservación y supresión por tipo de dato y los anexos éticos del proyecto están en `02_Evidencias/Etica/`, conforme a la Ley Orgánica de Protección de Datos Personales del Ecuador [39].

La declaración de uso de inteligencia artificial, sección por sección, con herramienta, tipo de asistencia y método de validación aplicado, consta en el Anexo E.

Referencias

- [1] K. Polin, T. Yigitcanlar, M. Limb, and T. Washington, “The making of smart campus: A review and conceptual framework,” *Buildings*, vol. 13, no. 4, p. 891, mar 2023.
- [2] X. Zhang, Y. Ding, X. Huang, W. Li, L. Long, and S. Ding, “Smart classrooms: How sensors and AI are shaping educational paradigms,” *Sensors*, vol. 24, no. 17, p. 5487, aug 2024.
- [3] M. Kurni and K. G. Srinivasa, “IoT-based smart classroom,” in *The Internet of Educational Things*. Cham: Springer, 2025.
- [4] C. Arora, J. Grundy, and M. Abdelrazek, “Advancing requirements engineering through generative AI: Assessing the role of LLMs,” *Communications of the ACM*, vol. 67, no. 6, pp. 84–91, 2024.
- [5] H. Cheng, J. H. Husen, Y. Lu, T. Racharak, N. Yoshioka, N. Ubayashi, and H. Washizaki, “Generative AI for requirements engineering: A systematic literature review,” *Software: Practice and Experience*, vol. 56, no. 2, pp. 141–170, 2026.
- [6] A. Vogelsang and J. Fischbach, “Using large language models for natural language processing tasks in requirements engineering: A systematic guideline,” arXiv, Tech. Rep. 2402.13823, 2024.
- [7] K. Ronanki, C. Berger, and J. Horkoff, “Investigating ChatGPT’s potential to assist in requirements elicitation processes,” in *2023 49th Euromicro Conference on Software Engineering and Advanced Applications (SEAA)*. IEEE, 2023, pp. 354–361.
- [8] B. Görer and F. B. Aydemir, “Generating requirements elicitation interview scripts with large language models,” in *2023 IEEE 31st International Requirements Engineering Conference Workshops (REW)*. IEEE, 2023, pp. 44–51.
- [9] C. Almeida, I. Copque, A. Oliveira, M. Arouca, A. Barbosa, S. Freire, M. Mendonça, and J. C. Leite, “From elicitation interviews to software requirements: Evaluating LLM performance in requirement generation,” in *Proceedings of the 28th Workshop on Requirements Engineering (WER 2025)*, Rio de Janeiro, Brazil, 2025.
- [10] A. Tikayat Ray, B. F. Cole, O. J. Pinon Fischer, A. P. Bhat, R. T. White, and D. N. Mavris, “Agile methodology for the standardization of engineering requirements using large language models,” *Systems*, vol. 11, no. 7, 2023.
- [11] K. Ronanki, B. Cabrero-Daniel, and C. Berger, “ChatGPT as a tool for user story quality evaluation: Trustworthy out of the box?” in *AI-Assisted Agile Software Development Workshop, co-located with XP 2023*, 2023.
- [12] ISO/IEC/IEEE, “ISO/IEC/IEEE 29148:2018 — systems and software engineering — life cycle processes — requirements engineering,” International Organization for Standardization, Geneva, Switzerland, Tech. Rep., 2018.
- [13] ISO/IEC, “ISO/IEC 25010:2023 — systems and software engineering — systems and software quality requirements and evaluation (SQuARE) — product quality model,” International Organization for Standardization, Geneva, Switzerland, Tech. Rep., 2023.

- [14] K. Pohl, *Requirements Engineering: Fundamentals, Principles, and Techniques*. Berlin, Heidelberg: Springer, 2010.
- [15] I. Sommerville, *Software Engineering*, 10th ed. Boston: Pearson, 2015.
- [16] H. Washizaki and IEEE Computer Society, “Guide to the software engineering body of knowledge, version 4.0,” IEEE Computer Society, Los Alamitos, CA, USA, Tech. Rep., 2024.
- [17] S. Lubos, A. Felfernig, T. N. T. Tran, D. Garber, M. El Mansi, S. P. Erdeniz, and V.-M. Le, “Leveraging LLMs for the quality assurance of software requirements,” in *Proceedings of the 32nd IEEE International Requirements Engineering Conference (RE 2024)*, Reykjavik, Iceland, 2024, pp. 389–397.
- [18] C. Hymel and H. Johnson, “Analysis of LLMs vs human experts in requirements engineering,” 2025.
- [19] K. Challa, I. W. AlHmoud, C. Jaiswal, B. Gokaraju, and R. Tesireo, “Gas sensors and real-time video for accurate classroom occupancy detection,” *MethodsX*, 2025.
- [20] M. Țălu, “Exploring IoT applications for transforming university education: Smart classrooms, student engagement, and innovations in teacher and student-focused technologies,” *Buletin Ilmiah Sarjana Teknik Elektro*, vol. 7, no. 1, pp. 9–29, 2025.
- [21] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell, and A. Wesslén, *Experimentation in Software Engineering*. Berlin, Heidelberg: Springer, 2012.
- [22] L. Montgomery, D. Fucci, A. Bouraffa, L. Scholz, and W. Maalej, “Empirical research on requirements quality: a systematic mapping study,” *Requirements Engineering*, vol. 27, no. 2, pp. 183–209, 2022.
- [23] P. Runeson and M. Höst, “Guidelines for conducting and reporting case study research in software engineering,” *Empirical Software Engineering*, vol. 14, no. 2, pp. 131–164, 2009.
- [24] A. Jedlitschka, M. Ciolkowski, and D. Pfahl, “Reporting experiments in software engineering,” in *Guide to Advanced Empirical Software Engineering*, F. Shull, J. Singer, and D. I. K. Sjøberg, Eds. London: Springer, 2008, pp. 201–228.
- [25] J. S. Molléri, K. Petersen, and E. Mendes, “An empirically evaluated checklist for surveys in software engineering,” *Information and Software Technology*, vol. 119, p. 106240, 2020.
- [26] B. Kitchenham and S. Charters, “Guidelines for performing systematic literature reviews in software engineering,” Keele University and Durham University, Keele, UK, Tech. Rep. EBSE 2007-001, 2007.
- [27] M. M. Hennink, B. N. Kaiser, and V. C. Marconi, “Code saturation versus meaning saturation: How many interviews are enough?” *Qualitative Health Research*, vol. 27, no. 4, pp. 591–608, 2017.
- [28] G. Guest, A. Bunce, and L. Johnson, “How many interviews are enough? an experiment with data saturation and variability,” *Field Methods*, vol. 18, no. 1, pp. 59–82, 2006.

- [29] B. A. Nosek, C. R. Ebersole, A. C. DeHaven, and D. T. Mellor, “The preregistration revolution,” *Proceedings of the National Academy of Sciences*, vol. 115, no. 11, pp. 2600–2606, 2018.
- [30] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [31] J. L. Fleiss, “Measuring nominal scale agreement among many raters,” *Psychological Bulletin*, vol. 76, no. 5, pp. 378–382, 1971.
- [32] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [33] L. Chazette and K. Schneider, “Explainability as a non-functional requirement: challenges and recommendations,” *Requirements Engineering*, vol. 25, no. 4, pp. 493–514, 2020.
- [34] L. Chazette, W. Brunotte, and T. Speith, “Exploring explainability: A definition, a model, and a knowledge catalogue,” in *Proceedings of the 29th IEEE International Requirements Engineering Conference (RE’21)*, 2021, pp. 197–208.
- [35] —, “Explainable software systems: from requirements analysis to system evaluation,” *Requirements Engineering*, vol. 27, no. 4, pp. 457–487, 2022.
- [36] M. D. Wilkinson, M. Dumontier, I. J. Aalbersberg, G. Appleton, M. Axton, A. Baak, N. Blomberg, J.-W. Boiten, L. B. da Silva Santos, P. E. Bourne *et al.*, “The FAIR guiding principles for scientific data management and stewardship,” *Scientific Data*, vol. 3, no. 160018, pp. 1–9, 2016.
- [37] A. M. Smith, D. S. Katz, K. E. Niemeyer, and FORCE11 Software Citation Working Group, “Software citation principles,” *PeerJ Computer Science*, vol. 2, p. e86, 2016.
- [38] S. Druskat, J. H. Spaaks, N. Chue Hong, R. Haines, J. Baker, S. Bliven, E. Willighagen, Y. Perez-Riverol, and A. Israel, “Citation file format (version 1.2.0),” 2021, software.
- [39] Asamblea Nacional del Ecuador, “Ley orgánica de protección de datos personales,” Registro Oficial Suplemento No. 459, Tech. Rep., 2021.
- [40] R. J. Delgado Mera and B. Véliz Noboa, “Sistema internet de las cosas (IOT), para la automatización y monitoreo de iluminación y climatización: Impulso a la eficiencia energética en aulas universitarias,” *RIEMAT*, vol. 11, no. 1, pp. 1–14, jan 2026.
- [41] P. Chaudhari, Y. Xiao, M. M.-C. Cheng, and T. Li, “Fundamentals, algorithms, and technologies of occupancy detection for smart buildings using IoT sensors,” *Sensors*, vol. 24, no. 7, p. 2123, 2024.

A. Instrumento de auditoría de calidad

La Tabla 6 recoge las seis métricas con su resultado y su veredicto. Conteos base publicados antes de calcular cada métrica, y resultado obtenido. El detalle con la aritmética visible, el veredicto y la acción de mejora de cada métrica está en `01_ERS/Auditoria_Calidad/`.

Tabla 6: Métricas de calidad de la especificación.

Métrica	Resultado	Referencia	Veredicto
Compleitud	100 %	≥ 95 %	Cumple
Consistencia	1,0000 sin conflictos abiertos	$\geq 0,98$ y cero conflictos	Cumple
Verificabilidad	100 %	≥ 90 %	Cumple
Trazabilidad	96,0 % y 100 %	100 % y ≥ 90 %	No cumple
Modificabilidad	4,00 declarada y comprobable	$\leq 3,0$	No cumple
Corrección	0,04 (1 residual / 25 RF)	$\leq 0,05$	Cumple

Tres de estos valores cambiaron el 30 de agosto respecto de la primera medición, y conviene decir por qué. La **compleitud** subió de 96,0 % a 100 % al comprobarse a mano que la única ficha marcada como incompleta, la de RF-01, sí tenía sus ocho atributos: el recuento automático no atravesaba el marcado de color de su fila de encabezado. La **verificabilidad** subió al reescribirse el criterio de RF-14, que exigía recomendaciones «coherentes» sin definir cómo comprobarlo. Y la **consistencia** cerró su único conflicto abierto al delimitarse RF-13 y RF-16 por causa, conforme a la solicitud de cambio SC-01. La **trazabilidad** se volvió a medir el 2026-09-15 sobre la matriz vigente: la cadena adelante llega al 100 % y la fuente de campo al 96,0 %, que sigue sin cumplir la referencia porque RF-25 no procede de una entrevista.

La **corrección** se calcula sobre los defectos residuales tras una re-inspección, y por eso fue la última en medirse. La inspección **INS-01** registró dieciséis defectos y la re-inspección **REINS-01**, del 5 de septiembre, cerró quince: queda uno residual, **DEF-06**, diferido de forma expresa por el comité en **SC-03**. De ahí sale $1/25 = 0,04$, por debajo del 0,05 de referencia. El margen es de un solo defecto: con dos residuales no cumpliría. La **trazabilidad** y la **modificabilidad** siguen sin cumplir, y sus acciones correctivas están definidas en `01_ERS/Auditoria_Calidad/`.

B. Banco de preguntas del tribunal

El banco completo, con una respuesta por pregunta del temario y el artefacto que respalda cada respuesta, está en `08_Defensa/banco_preguntas.md`. Cubre ocho bloques: sistema y partes interesadas, especificación, modelado y trazabilidad, componente empírico, ética y datos, componentes de inteligencia artificial, gestión del repositorio, y las limitaciones del propio estudio.

C. Aporte individual

La declaración completa está en `04_Trazabilidad/aporte_individual.csv`. Cada fila cita el identificador del commit que la respalda y el repositorio en el que se resuelve. Las filas sin identificador corresponden a integrantes sin aporte registrado en el historial, y se declaran como

tales.

D. Retrospectiva del equipo

La Tabla 7 recoge lo que funcionó, lo que no y lo que se hará distinto, con un responsable y una acción por cada entrada.

Tabla 7: Retrospectiva por categoría, con responsable y acción.

Categoría	Elemento	Responsable	Acción
Lo que funcionó	El pipeline reproducible permitió rehacer el análisis completo sin miedo a romper nada.	Analista líder	Construirlo antes en el próximo proyecto
Lo que funcionó	El material fuente compartido entre ambos brazos aisló el origen como única variable.	Equipo	Conservar el diseño en futuras réplicas
Lo que funcionó	El consentimiento informado se aplicó con rigor, y el retiro de EV-15 se respetó sin excepción.	Gestión de evidencias	Mantener el procedimiento
Lo que falló	El protocolo se registró después de recolectar; la desviación no admite reparación.	Analista líder	Registrar antes de la primera sesión
Lo que falló	La unidad de análisis se fijó en el juez y no en el ítem, con pérdida grave de potencia.	Analista líder	Rehacer el análisis por ítem
Lo que falló	Las dependencias entre requisitos no se declararon, y la métrica de modificabilidad engañó.	Especificación	Declararlas y volver a medir
Lo que mejorar	Calibrar a los jueces antes de evaluar, para elevar el acuerdo por encima de justo.	Componente empírico	Ítems de entrenamiento previos
Lo que mejorar	Obtener fuente de campo para RF-25, el único requisito sin entrevista de origen; la cadena de los trece incompletos se cerró el 2026-09-12.	Trazabilidad	Consultarlo con un participante
Lo que mejorar	Ejecutar la inspección formal para poder medir la corrección de la especificación.	Verificación	Sesión con roles y tiempos

Observaciones del docente y su resolución

Las observaciones recibidas durante el proyecto forman parte de su proceso. La Tabla 8 recoge las del informe de evaluación del 2026-09-05, las de la evaluación de la Entrega Final del 2026-09-14 y las de la guía de cierre de esa misma fecha, con lo que se hizo y dónde se comprueba en el repositorio.

Tabla 8: Observaciones del docente, resolución y evidencia.

Fuente	Observación	Resolución	Evidencia
Informe 2026-09-05, G3	La composición del equipo cambió sin autorización previa por escrito.	Se redactó, firmó y depositó la solicitud de cambio de composición (2026-09-08).	04_Trazabilidad/2026-09-08_Solicitud_Cambio_Composicion.pdf
Informe 2026-09-05, G8	Se contaron ocho videos y diez audios de entrevista.	Eran los de la zona pública. Desde el 2026-09-07 las grabaciones identificables están en el repositorio, en el contenedor cifrado, y el inventario técnico recoge 36: 19 de video y 17 de audio.	02_Evidencias/00_Restringido/fichas_tecnicas.csv
Informe 2026-09-05, C1	La portada del ERS no reflejaba a los integrantes acreditados.	Portada corregida con los tres integrantes.	01_ERS/ERS_SRS_2B_v2.0.tex
Informe 2026-09-05, C5	El registro de Zenodo declaraba un solo autor.	Los tres integrantes constan como autores, con ORCID.	CITATION.cff
Informe 2026-09-05	El <code>fair_assessment</code> no procedía de F-UJI.	Evaluación ejecutada con F-UJI 4.0.0 y depositada tal como la devuelve (2026-09-07).	fair_assessment.json
Informe 2026-09-05	Faltaba la retrospectiva con acciones y responsables.	Tabla 7, con responsable y acción por entrada.	Este anexo
Informe 2026-09-05, C8	El historial empezaba el 30/08 y la evidencia de campo era anterior.	Migración documentada con origen, fecha y motivo.	CHANGELOG.md
Evaluación 2026-09-14, B4	Tamaños del efecto con intervalos sin sentido sobre tres jueces.	Efecto con el requisito como unidad (desviación 7), y columnas de pares efectivos e interpretabilidad calculadas por script.	07_Datos/resultados/estadisticos/efectos.csv
Evaluación 2026-09-14, B1	La cadena de las tablas seguía en <code>06_Experimento</code> .	La orden única ejecuta la cadena desde <code>07_Datos</code> ; <code>06_Experimento</code> conserva la suya, protegida por la regla de no retroceso.	07_Datos/scripts/run_all.py
Guía de cierre 2026-09-14, §15	Faltaban notas de campo frente a las sesiones de elicitación.	Las seis notas existentes, con el nombre pedido; la bitácora declara por qué las otras catorce sesiones no tienen nota. No se elaboraron notas a posteriori.	10_Autoria/bitacora_sesiones.csv
Guía de cierre 2026-09-14, §1	La URL dejó de ser canónica tras el cambio de propietario.	Carátula, <code>CITATION.cff</code> , <code>README.md</code> y enlaces a la entrega 2A actualizados.	<code>CITATION.cff</code>
Reclamo del equipo, 2026-09-12	Objeciones a la rúbrica de cierre: A3, fuentes editables, capturas y EXIF, y composición del equipo.	Aceptadas las cuatro el 2026-09-13.	10_Autoria/retrospectiva_equipo.md
Reclamo del equipo, 2026-09-14	Escala de factores y factor individual proporcional a los commits.	El docente respondió con la guía de cierre del examen suspenso, que calcula la nota de otra forma.	10_Autoria/retrospectiva_equipo.md
Reclamo del equipo, 2026-09-16	El informe recibido citaba un commit, una etiqueta y archivos de otro repositorio.	El docente reconoció el error y recalificó sobre <code>98f1a6b</code> .	10_Autoria/retrospectiva_equipo.md

Tabla 8: Observaciones del docente, resolución y evidencia.

Fuente	Observación	Resolución	Evidencia
Informe 2026-09-16, §16	El manuscrito repetía el intervalo retirado; los κ no tenían intervalo; la tabla por requisito no declaraba pares ni interpretabilidad.	Cifra retirada; cada κ con su intervalo del 95 % en las tablas y en el texto; columnas de pares e interpretabilidad calculadas por script.	07_Publicacion/manuscrito_final.tex
Informe 2026-09-16, §16	Faltaba una retrospectiva con el reclamo y su resolución, quién hizo qué y lo aprendido.	Retrospectiva del cierre, posterior a las correcciones.	10_Autoria/retrospectiva_equipo.md
Informe 2026-09-16, §15	Faltaba emparejar cada fuente editable con su imagen, y la descripción de la bitácora estaba desfasada.	Tabla fuente-imagen generada por script; la bitácora se describe sin un recuento fijo y se regenera en cada cierre.	10_Autoria/README.md
Informe 2026-09-16, §3	La etiqueta congelaba un estado con §15 y §16 por modificar.	Nueva etiqueta anotada 2B-final-v5.11 sobre el último commit.	README.md

E. Declaración de uso de inteligencia artificial

La declaración completa, sección por sección, con herramienta empleada, tipo de asistencia y método concreto de validación aplicado, está en 10_Autoria/declaracion_uso_ia.md.

Los modelos de lenguaje intervienen en este trabajo en dos capacidades separadas. Como **objeto de estudio**, generando el conjunto de requisitos que constituye uno de los dos brazos del cuasi-experimento, con la instrucción que recibió, el modelo y la interfaz registrados en 06_Experimento/prompts_llm/. Y como **apoyo de redacción** sobre contenido escrito y verificado por el equipo.

Ninguna cifra, tabla, figura ni resultado estadístico de este reporte procede de un modelo de lenguaje: todos se generan por script desde los datos crudos, con la correspondencia declarada en el apartado 6 de 07_Datos/README_datos.md.

F. Correspondencia entre afirmación y resultado

Cada afirmación de la discusión remite a un resultado concreto o a una referencia verificable, según el trazado de la Tabla 9.

Esa tabla se lee, pero no se comprueba sola. Para que tampoco dependa de que alguien la revise a mano, las afirmaciones que llevan cifra se **recalculan desde su fuente** con 07_Publicacion/verificar_afirmaciones.py, que avisa si alguna dejó de coincidir y nombra los documentos que habría que corregir. Cubre un fallo que ninguna otra verificación del repositorio detecta: que un número escrito en prosa se quede atrás cuando el análisis se vuelve a ejecutar.

Tabla 9: Trazado de las afirmaciones de la discusión.

Afirmación	Resultado o referencia que la sostiene
El conjunto del modelo obtuvo media superior en las cinco dimensiones	resumen_resultados.csv; Tabla de descriptivos
Ninguna dimensión alcanza significación tras Holm-Bonferroni	hipotesis.csv, columna de p ajustado
Todos los intervalos de confianza del efecto incluyen el cero	efectos.csv; Figura 3
La potencia alcanzada es del 8,4 %	power_calculation.csv
Consistencia interna fue la dimensión más próxima a significación	hipotesis.csv, $p = 0,059$ ajustado
La uniformidad de una generación en una sola pasada explicaría esa señal	Hipótesis a contrastar; literatura [7, 8]
El acuerdo entre evaluadores es justo	acuerdo_interevaluador.csv; escala de [32]
La saturación temática se alcanzó con las 16 entrevistas	saturacion_por_entrevista.csv; robustez_saturacion.py; Figura 4
El diseño de material fuente compartido es la contribución principal	Protocolo registrado, sección de controles
La modificabilidad declarada y la medida coinciden en 4,00	01_ERS/Auditoria_Calidad/
El prototipo cubre el 85 % de los requisitos obligatorios	05_MVP/cobertura_requisitos.csv